

Gestión de la Información en la Web
Curso 2026-27
Práctica 5 – Web Scraping

Fecha de entrega: domingo 1 de noviembre de 2026

Entrega de la práctica

La entrega de la práctica se realizará a través del Campus Virtual de la asignatura mediante un fichero `pr5.py`. El esqueleto de este fichero se puede descargar del Campus Virtual.

Lenguaje de programación

Python 3.13 o superior.

Calificación

Se medirá la corrección mediante tests de unidad. Además de la corrección, se valorará la **calidad, concisión y claridad del código**, la incorporación de **comentarios** explicativos, su **eficiencia** tanto en tiempo como en memoria y la puntuación obtenida en Pylint.

Declaración de autoría e integridad

Todos los ficheros entregados contendrán una cabecera en la que se indique la asignatura, la práctica, el grupo y los autores. Esta cabecera también contendrá la siguiente declaración de integridad:

Declaramos que esta solución es fruto exclusivamente de nuestro trabajo personal. No hemos sido ayudados por ninguna otra persona o sistema automático ni hemos obtenido la solución de fuentes externas, y tampoco hemos compartido nuestra solución con otras personas de manera directa o indirecta. Declaramos además que no hemos realizado de manera deshonesto ninguna otra actividad que pueda mejorar nuestros resultados ni perjudicar los resultados de los demás.

No se corregirá ningún fichero que no venga acompañado de dicha cabecera.

Se va a considerar una página web de una tienda online ficticia: <https://books.toscrape.com/>. En la tienda se muestran diferentes libros a comprar agrupados en 50 categorías. En cada categoría se muestran los libros incluidos utilizando paginación de 20 elementos, y por cada libro se muestran datos como la portada, el título, la valoración, el precio, etc. Cada libro además tiene su página específica con la descripción del libro y otros detalles.




Figura 1: Página principal de la categoría «Nonfiction»




Figura 2: Detalle de paginación

En esta práctica se implementarán distintas funciones Python para extraer información de esta página y devolver listas con los datos buscados.

1. Listado de categorías [4pt]

Implementar una función `categorias()` que devuelve un **conjunto de parejas**

(nombre, número de libros)

de todas las categorías que existen en la tienda. Para simplificar este proceso, se *recomienda* implementar también una función auxiliar `explora_categoria(url)` que a partir de la URL de la página principal de una categoría, devuelve el nombre de la categoría y el número de libros.

Ejemplo:

```
1 >>> categorias()
2 {'Academic', 1},
3 ('Add a comment', 67),
4 ('Adult Fiction', 1),
5 ('Art', 8),
6 ...
7 }
```

2. Listado de los libros de una categoría [6pt]

Implementar una función `libros_categoria(nombre)` que recibe el nombre de una categoría y devuelve un **conjunto de tuplas**

(titulo, precio, valoración)

donde cada tupla representa a un libro, el precio es un número real y la valoración es un número natural. En caso de que no exista ninguna categoría con dicho nombre, devolverá el conjunto vacío. Para determinar si una categoría existe se deberán ignorar espacios al principio y final y también diferencias en mayúsculas/minúsculas, es decir, «**Sequential Art**» y « **SeQuential ART** » se considerarán la misma categoría.

Ejemplos:

```
1 >>> libros_categoria('Historical Fiction')
2 {'A Flight of Arrows (The Pathfinders #2)', 55.53, 5},
3 ('A Paris Apartment', 39.01, 4),
4 ('A Spy's Devotion (The Regency Spies of London #1)', 16.97, 5),
5 ...
6 }
7 >>> libros_categoria('Invent')
8 set()
```

Para simplificar este proceso, se *recomienda*¹ implementar las siguientes funciones auxiliares:

- `url_categoria(nombre)`: devuelve la URL de la página principal de una categoría a partir de su nombre. Para esta búsqueda debéis ignorar espacios al principio y final y también diferencias en mayúsculas/minúsculas.

¹No es obligatorio, únicamente una posible pista para organizar y reutilizar el código.

- `todas_las_paginas(url)`: a partir de la URL de una página, sigue la **paginación hacia delante** devolviendo una lista con todas las **URL absolutas** atravesadas (incluyendo la URL inicial).

Comentarios relevantes:

- Los enlaces de los botones «next» son relativos a la página actual, así que para generar la lista de URL absolutas deberéis utilizar el método `urljoin`² de la biblioteca `urllib.parse`.
- Deberéis ser capaces de transformar la información de la valoración mediante estrellas a un valor numérico entero.
- En las páginas del catálogo a veces aparecen títulos acortados que acaban en puntos suspensivos, por ejemplo, el libro «*Sapiens: A Brief History of Humankind*» se visualiza como «*Sapiens: A Brief History ...*» en el listado de su categoría. Sin embargo, si exploráis el código fuente HTML de la página del catálogo podréis encontrar el título completo en alguna parte del mismo elemento sin necesidad de abrir cada una de las páginas con los detalles específicos de cada libro.

²<https://docs.python.org/3/library/urllib.parse.html#urllib.parse.urljoin>